



SafeWatch - Sistema de detecção de quedas para Smartwatches

Por

Victor de Souza Tavares

Trabalho de Graduação



Universidade Federal da Bahia
wiki.dcc.ufba.br/DCC/

SALVADOR, Outubro/2016



Universidade Federal da Bahia
Departamento de Ciência da Computação

Victor de Souza Tavares

SafeWatch - Sistema de detecção de quedas para Smartwatches

Trabalho apresentado ao Departamento de Ciência da Computação da Universidade Federal da Bahia como requisito parcial para obtenção do grau de Bacharel em Ciência da Computação.

Orientador: *Vaninha Vieira*

SALVADOR, Outubro/2016

*Dedico esta dissertação à minha família, amigos e
professores que me deram todo o apoio necessário para
chegar até aqui.*

*Always code as if the guy who ends up maintaining your code will be a
violent psychopath who knows where you live*

—JOHN WOODS

Resumo

A queda é um problema grave de saúde pública que afeta principalmente a população idosa, onde está relacionado com a perda de confiança, autoestima, e autonomia. Este problema se mostra ainda mais relevante se consideramos o crescente número de idosos, que em busca de sua independência e autonomia decidem morar sozinhos. Pensando nisso, foi desenvolvido o *SafeWatch*, um sistema de detecção de quedas embarcado em smartwatches já presentes no mercado. O sistema proposto irá monitorar o idoso através de sensores presentes no smartwatch, e ao detectar uma queda, além de vibrar no pulso do usuário, irá informar para uma lista de contatos de emergência do usuário a sua localização e a possibilidade do idoso estar em uma situação de perigo. De acordo com os experimentos realizados foi possível detectar o grau de confiabilidade da aplicação através dos valores de *Sensibilidade* e *Especificidade* que atingiram uma média de X% e Y% respectivamente.

Palavras-chave: Relógios Inteligentes, Reconhecimento de Atividade, Queda, Idoso

Abstract

In Brazil and several other countries worldwide the elderly population is growing, and with that, their wish to be more independent. Being a niche of the population much more susceptible to falls and problems derived from this event, this paper proposes a fall detection system embedded in smartwatches already present on the market. The proposed system will monitor the elderly through sensor present in the smartwatches, more specifically the gyroscope and accelerometer, and through the fall detection algorithm, it will report to the user's contact list his location and an alert informing that the elderly is in dangerous situation. The confiability of the proposed application is evaluated through the values of *Sensitivity* and *Specificity*.

Keywords: Smartwatch, Activity Recognition , Fall, Elderly

Sumário

Lista de Figuras	xv
Lista de Tabelas	xvii
Lista de Acrônimos	xix
Lista de Códigos Fonte	xxi
1 Introdução	1
2 Sistemas de Detecção de Queda	5
2.1 Definição de Queda	5
2.2 Tipos de Sistemas de Detecção de Queda	7
2.2.1 Sistemas de Detecção Baseados no Ambiente	7
2.2.2 Sistemas de Detecção Baseados na Visão	8
2.2.3 Sistemas de Detecção Baseados em Tecnologias Vestíveis	9
3 Sistemas Vestíveis	11
3.1 Sensores	11
3.1.1 Acelerômetro	12
3.1.2 Giroscópio	13
3.2 Posicionamento de Sensores	14
3.3 Algoritmos de Detecção de Queda	14
3.3.1 Reconhecimento de Padrões	15
3.3.2 Baseado em Limiares	16
3.4 Trabalhos Relacionados	17
Referências Bibliográficas	18

Lista de Figuras

2.1	Etapas de uma queda (Hsieh <i>et al.</i> , 2014).	6
3.1	Sistema de coordenadas utilizado pelo sistema operacional Android (Google, 2016a).	12
3.2	Força sendo aplicado sobre uma massa presa a molas (Milette and Stroud, 2012).	13
3.3	Modelo de árvore de decisão construída em Zhao <i>et al.</i> (2012).	15

Lista de Tabelas

Lista de Acrônimos

PNAD	Pesquisa Nacional por Amostra de Domicílio
FDS	Sistema de Detecção de Queda
ADL	Atividades diárias
FOF	Fear of Falling
MEMS	Sensores Microeletromecânicos
SMV	Magnitude Vetorial

Lista de Códigos Fonte

1

Introdução

The most profound technologies are those that dissapear. They weave themselves into the fabric of everyday life until they are indistinguishable from it.

—MARK WEISER

Devido a diversos avanços tecnológicos e médicos, a população mundial vem envelhecendo de forma gradual. Projeções feitas pelas [United Nations \(2013\)](#), indicam que 11,57% da população mundial tem 60 anos ou mais. Este mesmo relatório aponta que em 2050 a porcentagem de idosos irá quase dobrar, correspondendo a 21,1% da população. Esta tendência não é muito diferente no Brasil, onde de acordo com as projeções do [IBGE \(2016\)](#), 8,17% da população irá ter 65 anos ou mais em 2016, com este número aumentando para 13,44% em 2030.

Além de ser uma parcela da população que cresce, o número de idosos que moram sozinhos também vem aumentando. De acordo com o [IBGE \(2012\)](#), entre 1992 e 2012, este número triplicou no Brasil, passando de 1,1 milhão para 3,7 milhões, um aumento de 215%. Na busca pela sua independência, o idoso fica vulnerável a um dos principais problemas desta faixa etária, as quedas. De acordo com um estudo da Organização Mundial de saúde, de 28% a 35% da população maior do que 64 anos sofrem pelo menos uma queda por ano. De acordo com o [Portal Brasil \(2012\)](#), o SUS (Sistema Único de Saúde) registra a cada ano, um gasto de mais de R\$ 51 milhões com o tratamento de fraturas decorrentes de queda. Além de custosos, estas quedas representam um risco muito grande para o idoso, casos mais graves de fatura pode levar até morte, como por exemplo a fratura de fêmur com um índice de mortalidade de 30%.

Outra questão que torna as quedas ainda mais prejudiciais a saúde física e mental do

idoso é o tempo entre a queda e o atendimento médico. De acordo com diversos estudos, a demora no atendimento está fortemente ligada ao índice de mortalidade e gravidade do acidente depois de uma queda. De acordo com X, quando ocorre o “long-lie”, ou seja, o idoso permanece mais de uma hora no chão a chance de que o idoso faleça antes dos 6 meses do ocorrido sobe para 50%.

Visando minimizar essas graves consequências das quedas, diversos sistemas de detecção foram desenvolvidos nos últimos anos, porém estes sistemas não fazem uso de tecnologias mais popularizadas no mercado, ou utilizam de plataformas que não são vestíveis, prejudicando a mobilidade do usuário.

Por exemplo, diversos sistemas utilizam o smartphone como principal plataforma na detecção de quedas. Analisando somente as questões de popularidade e hardware, o smartphone se apresenta uma solução plausível. De acordo com [Gartner \(2015\)](#), foram vendidos mais 1 bilhão de aparelhos somente em 2014. Na perspectiva de hardware, a maioria dos smartphones modernos possuem giroscópio ou acelerômetro, dois dos principais sensores utilizados no reconhecimento de atividades atualmente.

Entretanto, quando pensamos em mobilidade, o smartphone passa a ser uma solução com baixo potencial, pois para que os sistemas funcione corretamente o mesmo precisa está fixo em uma posição pré-estabelecida pelo sistema, como os bolso ou pulso do usuário [He et al. \(2012\)](#). O que faz com que, em situações corriqueiras, como colocar o celular na bolsa, possa gerar um número grande de falsos positivos.

Este trabalho propõe como solução a criação de um sistemas de detecção de quedas através de uma solução integrada entre smartphone e o smartwatch. Na primeira vez que executar a aplicação, o usuário deverá cadastrar o nome e-mail dos usuários que ele deseja contactar em caso de uma queda, feito este registro o usuário está pronto pra utilizar a aplicação. Ao detectar a queda, o smartwatch irá vibrar, e caso o usuário não indique que está bem, o sistema irá enviar um email com a localização do usuário para todos os contatos já cadastrados.

O smartwatch é uma ferramenta que permite que este tipo de aplicação seja calma e invisível para o usuário, além de ter uma capacidade de processamento bastante similar aos smartphones com uma popularidade crescente. A Samsung, umas das empresas pioneiras no mercado de smartwatches, lançou em outubro de 2015 o Samsung Gear S2. O Gear é um exemplo de como esses sistemas estão cada vez mais poderosos. Ele possui uma memória RAM de 512 MB e 4GB de armazenamento, conectividade WiFi e 4G além de diversos sensores como giroscópio e acelerômetro [Samsung \(2016\)](#). A popularidade desta plataforma é vista através do número de smartwatches vendidos. No

ano de 2015, 30,32 milhões de aparelhos foram vendidos, e a previsão é de que, em 2016, este número suba para 50,40 milhões.

Os próximos capítulos estão organizados da seguinte maneira: O Capítulo ?? apresenta os conceitos teóricos usados neste trabalho referente a Sistemas de Detecção de Quedas. O Capítulo ?? apresenta o SafeWatch, o sistema de Detecção de Quedas desenvolvido através de uma solução integrada entre o smartphone e o smartwatch. O Capítulo ?? apresenta o experimento realizado, e realiza a avaliação da ferramenta. Por fim, no capítulo ??, seguem as conclusões e considerações finais.

2

Sistemas de Detecção de Queda

Um Sistema de Detecção de Queda ([FDS](#)), pode ser descrito com um dispositivo de apoio, cujo principal objetivo é alertar o usuário em um evento de queda ([Igual et al., 2013](#)). De forma geral, estes sistemas são capazes de distinguir Atividades diárias ([ADL](#)) de um evento de queda. Este tipo de sistema pode ser desenvolvido de diversas formas e pode estar tanto embarcado em um Dispositivo vestíveis como um smartwatch ou se basear em um sistema de monitoramento utilizando câmeras.

Com o uso de sistemas de detecção de quedas é possível que o usuário tenha o seu medo de cair reduzido, e dependendo da solução que foi desenvolvida, possa ser socorrido de maneira muito mais rápida, caso necessário. Um indivíduo que já sofreu uma queda, pode desenvolver uma síndrome chamada Fear of Falling ([FOF](#)), que pode levar a perda da capacidade de se realizar atividades rotineiras, como passear em um parque, ou assistir um filme em família ([Legters, 2002](#)).

As seções desse capítulo são organizadas da seguinte maneira: A seção [2.1](#) define o conceito de quedas e expõe os diversos estados da mesma; A [2.2](#) irá demonstrar os 3 diferentes tipos de sistemas de detecção quedas mais populares; A seção [3.1](#) irá demonstrar os principais sensores utilizados nos sistemas de detecção de quedas; Por fim, a seção ?? irá mostrar exemplos de aplicações que realizam a detecção de quedas.

2.1 Definição de Queda

De forma geral, podemos definir uma queda como um evento súbito e involuntário, onde o indivíduo de uma posição em pé ou sentado, passa a ocupar uma posição integral ou parcialmente deitada (Horizontal). Na busca por uma definição mais formal, em 1987, o Kellogg International Working Group on the prevention of falls, descreveu uma queda como "Vir ao chão ou algum nível mais baixo, sem a intenção como consequência de

um golpe violento, perda de consciência, ou início súbito de paralisia como no caso de um acidente vascular cerebral ou um ataque epiléptico"(Igual *et al.*, 2013). Quando analisamos uma queda através da perspectiva da aceleração do movimento, ela pode ser dividida em etapas descritas na imagem 2.1. Estas 4 etapas são as seguintes:




Figura 2.1 Etapas de uma queda (Hsieh *et al.*, 2014).

- **Período Anterior a Queda (Pre-Fall):** Durante este período o indivíduo estará realizando suas atividades cotidianas, que podem levar ou não a um pico de aceleração que deve ser tratado para que se possa evitar falso-positivos. Ações que geralmente levam a este pico de aceleração são movimentos como sentar ou se deitar muito rápido, ou dependendo da posicionamento dos sensores, atividades físicas que exigem bastante movimentação.
- **Período Anterior a Queda (Pre-Fall):** Durante este período o indivíduo estará realizando suas atividades cotidianas, que podem levar ou não a um pico de aceleração que deve ser tratado para que se possa evitar falso-positivos.
- **Período Queda Livre (Free-Fall):** Durante este período o indivíduo está se descolando em direção ao chão. Nesta fase o valor de sua aceleração irá tender a 0.

- **Período do Impacto (Impact-Phase):** Período caracterizado pelo impacto do indivíduo, este período é crítico na aplicação, pois é onde ocorre o pico de aceleração.
- **Período de Inatividade (Inactive State):** Período posterior a queda, onde o usuário irá realizar o esforço para se levantar. Em quedas mais graves, onde o usuário está incapaz de se movimentar ou inconsciente este valor de modificação de maneira muito sutil, porém de forma geral, o usuário que sofreu uma queda não se levanta imediatamente. De acordo com [Mehner et al. \(2013\)](#), o período de pós impacto e inatividade levá aproximadamente 2 segundos.

2.2 Tipos de Sistemas de Detecção de Queda

Diversos tipos de Sistemas de Detecção de Queda foram desenvolvidos nos últimos anos e estes utilizam diferentes abordagens buscando atingir o mesmo objetivo: realizar a detecção automática das quedas. De acordo com [Mubashir et al. \(2013\)](#), estes sistemas podem ser categorizados em três grupos: sistemas de detecção baseados no ambiente, sistemas de detecção baseados na visão, sistemas de detecção baseados em tecnologias vestíveis.

2.2.1 Sistemas de Detecção Baseados no Ambiente

Sistemas de detecção baseados no Ambiente utilizam a fusão de dados obtidos de diversos sensores para realizar a detecção de quedas. Através desses sensores são obtidos sinais audio-visuais e dados vibracionais do ambiente que está sendo monitorado. Este tipo de sistema podem ser divididos em duas categorias:

- **Audio-Visuais:** Neste tipo de sistema são analisados os sinais audio-visuais obtidos através de câmeras e microfones espalhados no ambiente desejado. Um exemplo deste sistema foi proposto por [Zhuang et al. \(2009\)](#), ele utiliza o padrão da onda sonora capturada, com uma base de dados treinada com diferentes tipos de onda sonoras associadas com diferentes tipos de eventos. Sendo assim, capaz de diferenciar uma queda de uma atividade diária.
- **Dados Vibracionais:** Neste tipo de sistema são analisados os dados vibracionais obtidos através de sensores de vibração espalhados no chão do ambiente desejado. Um exemplo deste sistema foi proposto por [Zhuang et al. \(2009\)](#), ele utiliza o padrão da onda sonora capturada, com uma base de dados treinada com diferentes

tipos de onda sonoras associadas com diferentes tipos de eventos. Sendo assim, capaz de diferenciar uma queda de uma atividade diária.

2.2.2 Sistemas de Detecção Baseados na Visão

Sistemas de detecção baseados na visão utilizam uma ou mais câmeras posicionadas ao redor do ambiente desejado para que se possa realizar a detecção de quedas. As câmeras são consideradas um meio menos intrusivo de detecção, pois, diferente dos sistemas que utilizam tecnologias vestíveis, somente o vídeo gerado pela câmera são utilizadas na detecção, sem a necessidade do usuário vestir nenhum dispositivo eletrônico. Diferentes tipos de técnicas de processamento de vídeo e imagem são utilizadas na detecção. As principais delas são:

- **Espaço-Temporais:** Sistemas que utilizam características espaço-temporais para realizar modelagens capazes de fornecer dados cruciais na detecção de diferentes tipos de atividades. Um sistema proposto por [Foroughi et al. \(2008\)](#) realiza a extração de informações de movimento de uma sequência de vídeo. Aplicando uma técnica chamada Eigenspace sobre as informações de movimento coletadas, é possível extrair um vetor de características, que é utilizado por um algoritmo de inteligência artificial, mais especificamente um algoritmo de redes neurais, para determinar o tipo de evento ocorrido.
- **Inatividade/Mudança de Forma:** Sistemas que utilizam mudanças de forma e ausência de atividade no monitoramento em vídeo para realizar a detecção de quedas. Um exemplo deste tipo de sistema foi proposto por [Rougier et al. \(2011\)](#). Em seu artigo, são utilizadas técnicas de detecção e análise de formas para detectar a silhueta e atividade (representado por mudanças de forma) do indivíduo que está sendo monitorado. Para que se possa diferenciar quedas das atividades diárias, é utilizado o método de *Mistura de Modelos Gaussianos*, um método estatístico utilizado em visão computacional.
- **Postura:** Sistemas que identificam e localizam diversas posturas do indivíduo, calculadas através das diferentes posições corporais, utilizando uma sequência de imagens para realizar a detecção um evento de queda. [Cucchiara et al. \(2005\)](#), desenvolveu um sistema de detecção que analisa os histogramas das imagens geradas pelas câmeras, para classificar as posturas do indivíduo monitorado e consequentemente detectar um evento de queda.

- **Análise 3D da Posição da Cabeça:** Sistemas que realizam o monitoramento da cabeça do indivíduo, e através de modelos de estado é capaz de detectar as magnitudes do movimento realizado. Um exemplo deste tipo de sistema foi proposto por [Rougier and Meunier \(2005\)](#), ele realiza a modelagem 3D da cabeça do indivíduo e capaz de calcular a velocidade e a trajetória deste modelo que são posteriormente utilizadas na categorização do evento como queda.

2.2.3 Sistemas de Detecção Baseados em Tecnologias Vestíveis

Sistemas vestíveis de detecção de quedas utilizam os dados de sensores que estão acoplados sobre ou na roupa dos usuários. Este tipo de sistema apresentam claras vantagens sobre tanto os sistemas baseados no ambiente ou na visão. Ambos os tipos de sistema, exigem um custo constante de manutenção, que dependendo de como o sistema foi desenvolvido, pode ser bastante alto, além disso a área de atuação do sistema fica limitada a uma área pré-determinada (e.g quarto, sala de estar). Utilizando tecnologias vestíveis não temos este problema, pois o usuário poderá levar o seu dispositivo para onde ele desejar.

Levando em consideração a privacidade do usuário, os sistemas vestíveis levam vantagem em relação aos baseados no ambiente e na visão. A necessidade de uma monitoração por vídeo constante necessária em alguns desses sistemas podem deixar o usuário relutante em implementar esta solução.

De acordo com [Igual et al. \(2013\)](#), o uso de smartphones para realizar a detecção de quedas tem sido uma tendência devido ao seu baixo preço, altos volumes de produção e facilidade de desenvolvimento. O grande problema do uso do smartphone é justamente o seu posicionamento. O aparelho pode estar em diversas posições, ou mesmo, nem diretamente ligado ao corpo do usuário. Esta incerteza dificulta bastante o uso deste tipo de dispositivo no reconhecimento de atividades.

Tentando resolver este problema, o uso de aparelhos realmente vestíveis vem sendo utilizado em sistemas de detecção de quedas, como pode ser visto nos trabalhos desenvolvidos por [Hsieh et al. \(2014\)](#) e [Pivato et al. \(2011\)](#).

3

Sistemas Vestíveis

Sistemas Vestíveis podem ser definidos como dispositivos eletrônicos móveis que podem ser discretamente embutidos nos trajes do usuário, como parte da roupa ou um acessório. Diferente dos sistemas móveis convencionais, eles podem funcionar sem ou com muito pouca interferência nas atividades do usuário ([Lukowicz et al., 2004](#)).

Hoje, muitos destes dispositivos vestíveis vem com uma gama de sensores embutidos que são utilizados na detecção de quedas. O tipo de sensor mais comum utilizado em [FDS](#) é o acelerômetro, com alguns desses sistemas também utilizando o giroscópio como um sensor auxiliar. De acordo com a revisão sistemática feito por [Igual et al. \(2013\)](#), 186 dos 197 sistemas analisados utilizam o acelerômetro como sensor principal na detecção de quedas. A utilização desde sensores em [FDS](#) se deve muito pela popularização e o barateamento dos mesmos, além da utilização desses sensores embarcados em smartphones e smartwatches.

As seções desse capítulo são organizadas da seguinte maneira: A seção [3.1](#) descreve os principais tipos de sensores utilizados em [FDS](#); A [3.2](#) fala sobre o posicionamento de sensores, fazendo uma correlação entre o posicionamento dos sensores e a acurácia dos sistemas estudados; A seção [3.3](#) fala sobre os diferentes tipos de algoritmos de detecção de quedas mostrando suas vantagens e desvantagens; Por fim, a seção [3.4](#) irá mostrar exemplos de aplicações que realizam a detecção de quedas através de tecnologias vestíveis.

3.1 Sensores

A escolha e o bom funcionamento de sensores são uma parte essencial no bom funcionamento de sistemas de detecção de quedas. De forma geral, sensores são dispositivos que convertem fenômenos físicos em sinais elétricos. Sendo assim, eles representam a

camada de comunicação entre o mundo físico e o mundo digital.

Os dois tipos principais de sensores utilizados em sistemas de detecção de queda são o acelerômetro e o giroscópio. Eles fazem parte de um grupo chamado de Sensores Microeletromecânicos (**MEMS**). Estes sensores são geralmente feitos de chips de silício utilizando as mesmas técnicas usadas na confecção de chips de computadores pessoais. Para que um sensor possa ser classificado como **MEMS** alguma parte do seu design precisa vibrar ou se mover de alguma forma (Milette and Stroud, 2012).

De forma geral tanto o acelerômetro quanto o giroscópio utilizam 3 eixos para expressar seus valores. O sistema de coordenadas utilizado é relativo a cada dispositivo. Na figura 3.1 temos exemplo do sistema de coordenadas utilizado pelo sistema operacional Android¹. Neste sistema o ponto de origem é o centro da tela do dispositivo, quando segurado na posição vertical (Google, 2016a).




Figura 3.1 Sistema de coordenadas utilizado pelo sistema operacional Android (Google, 2016a).

3.1.1 Acelerômetro

Fisicamente, o acelerômetro é um dispositivo composto de uma pequena massa anexado a pequenas molas que são utilizadas para medir a aceleração aplicada sobre um dispositivo, incluindo a força da gravidade. A aceleração é medida analisando o quanto a massa se distancia do seu ponto de equilíbrio.

Na figura 3.2 em A é possível ver um aparelho parado em uma mesa, sobre ele só irá agir a força de gravidade $1G$ de aproximadamente $9.8m/s^2$. Em B, o aparelho foi jogado para a direita, então irá agir sobre ele, além da força da gravidade, uma aceleração no sentido para onde o aparelho se movimentou. Já em C, vemos um aparelho em queda

¹<https://www.android.com/>




Figura 3.2 Força sendo aplicado sobre uma massa presa a molas (Milette and Stroud, 2012).

livre com aceleração no sentido oposto a força da gravidade, o que faz com a massa fique localizada em seu ponto de equilíbrio, e a força resultante seja de 0G (Milette and Stroud, 2012).

3.1.2 Giroscópio

O giroscópio, similarmente aos acelerômetros, são pequenas massas em pequenas molas, só que em vez de medir a aceleração, são utilizados para medir um tipo de força chamada de Força de Coriolis. A Força de Coriolis é a tendência que um objeto livre possui de sair do curso quando visto de um ponto de referência em rotação (Milette and Stroud, 2012). Por exemplo, se sentarmos em um carrossel e rolarmos a bola pra longe, a bola irá parece desviar em uma linha reta, como se existisse uma força agindo sobre ela. Esta força é chamada de Força de Coriolis.

Apesar de possuir uma estrutura física semelhante, o aceletrometro e o giroscópio se diferem em seu funcionamento. Em vez de esperar a força da gravidade agir sobre a massa, o giroscópio funciona vibrando está massa sobre o eixo definido. Quando o giroscópio é rotacionado, a Força de Coriolis faz com que a massa comece a ser mover em um eixo dirente no qual ele estava vibrando anteriormente. Milette and Stroud (2012).

Como a força de Coriolis age somente quando o dispositivo está em rotação, o giroscópio só é capaz de calcular a velocidade angular, ou seja, a velocidade com que o aparelho está sendo rotacionado.

A orientação da dispositivo irá definir quando o valor da rotação será positivo ou negativo. Nos dispositivos Android, a velocidade Angular é medida em radianos por segundo (rad/s) e é positiva em rotações no sentido anti-horário (Google, 2016b).

3.2 Posicionamento de Sensores

O posicionamento dos sensores afeta diretamente a performance dos FDS, dependendo da posição onde colocamos os sensores, o sistema pode indicar uma maior ou menor quantidade de falhas.

Não existe um consenso sobre a posição otimizada dos sensores para que se possa realizar a detecção de quedas. De acordo com Abbate *et al.* (2011), a cintura seria o local ideal para o posicionamento, já que estaria mais perto do centro de gravidade do corpo humano. Entretanto em Kangas *et al.* (2007), já foi sugerido que a cabeça seria o melhor lugar para posicionar os sensores. Outras soluções, como em Gjoreski *et al.* (2011), já propõem o uso de mais de um sensor, colocando-os em diferentes partes do corpo com o objetivo de aumentar ainda mais a precisão dos FDS.

De acordo com X, o pulso não é o local recomendado para o posicionamento de sensores em sistemas de detecção de quedas. Isso se deve a constante movimentação dos braços, que podem gerar um número grande de falso-positivos. Entretanto, alguns sistemas tem conseguido resultados satisfatórios com FDS localizados no pulso. O sistema proposto por Hsieh *et al.* (2014), foi capaz detectar quedas em 151 das 160 quedas simuladas e obteve uma especificidade (capacidade de não reconhecer eventos de quedas, como tal) de 95%.

Além da acurrácia do sistema, outras questões precisam ser levadas em consideração quando pensamos no posicionamento dos sensores. Uma delas é a danificação dos sensores na ocorrência de uma queda. Caso o sistema pare de funcionar, um possível alerta de emergência poderá não ser enviado e o idoso poderá está correndo grande perigo.

Outra questão é a usabilidade, o uso de muitos sensores, apesar de poder elevar a precisão do sistema, poderá levar a um desconforto do usuário, que pode fazer até com que o mesmo desista de usá-lo.

3.3 Algoritmos de Detecção de Queda

Os algoritmos de detecção de quedas recebem como entrada os dados obtidos através dos sensores e são capazes de determinar se o que ocorreu foi um evento de queda ou somente uma ADL. De acordo com Casilari *et al.* (2015), é possível separar os algoritmos de detecção em dois grandes grupos: Algoritmos de detecção através de métodos de reconhecimento de padrões, algoritmos baseados em limiares.

3.3.1 Reconhecimento de Padrões

O reconhecimento de padrões é uma área do aprendizado de máquina que foca no reconhecimento de padrões e regularidades de dados (Anzai, 2012). Diversas técnicas de aprendizado de máquina tem sido empregadas na detecção de quedas, de acordo com a revisão sistemática feita por Casilari *et al.* (2015), algoritmos como o de *Naïve Bayes*, *Redes Neurais*, e *Árvores de Decisão* tem sido utilizados.

Um exemplo de sistema que utiliza a técnica de reconhecimento de padrões foi proposto por Zhao *et al.* (2012). O seu algoritmo de detecção de quedas analisa dados do acelerômetro através de uma árvore de decisão, assim identificando um evento de queda.

Este algoritmo é composto de 2 fases, a primeira é o que chamamos em aprendizado de máquina de fase de treinamento. Será realizado a coleta de dado e a extração das características que são pertinentes, além do treinamento de um modelo de árvore de decisão. Na figura 3.3 podemos ver o modelo de árvore de decisão gerado. Este modelo de árvore de decisão é capaz de reconhecer atividades como andar, correr, estado estático ou um evento de queda através das variáveis *Std_x*, *Mean_y* e *Slope* que representam características do sistema.




Figura 3.3 Modelo de árvore de decisão construída em Zhao *et al.* (2012).

Na segunda fase, chamada de fase de testes, o modelo de árvore de decisão é utilizado em uma aplicação no smartphone que será responsável pelo reconhecimento de atividades. Os dados dos sensores são catalogados e transformados nas características do sistema, que servirão como dados de entrada da árvore de decisão, que terá como saída o tipo de atividade que foi desempenhada.

Sistemas que utilizam reconhecimento de padrões, normalmente estão suscetíveis a altos custos computacionais, análise massiva de dados, e acesso a grandes bancos de dados ou longos períodos de treinamentos onde o algoritmo de classificação precisa ser

parametrizado e adaptado a diferentes grupos de usuários (Casilari *et al.*, 2015). Em contraste, existem os algoritmos baseados em limiares que tendem a ser mais simples e similarmente eficientes, desde que encontremos limiares adequados.

3.3.2 Baseado em Limiares

Algoritmos baseados em limiares utilizados na detecção de quedas comparam os dados dos sensores com um ou mais valores pré-definidos, chamados de limiares. Estes valores podem ser fixos ou adaptados. Quando estes valores são adaptados, eles não mudam dinamicamente enquanto os usuários estão utilizando o sistema. Em vez disso, o usuário irá introduzir dados sobre o seu perfil fisiológico e o sistema irá informar os limiares adequados (Habib *et al.*, 2014). Um exemplo deste tipo de sistema pode ser visto em Sposaro and Tyson (2009), o valor limiar mudar de acordo com os parâmetros providos pelo usuário como altura, peso e nível de atividade.

De acordo com a revisão sistemática feita por Casilari *et al.* (2015), muitos sistemas de detecção de queda utilizam o valor de Magnitude Vetorial (SMV) do vetor de aceleração como valor limiar principal em seus algoritmos de detecção. O valor de SMV é definido através da equação em 3.1, onde X_i , Y_i , Z_i , representam, respectivamente, os valores de aceleração dos eixos x, y, z obtidos através do acelerômetro descrito em 3.1.1.

$$SMV = \sqrt{X_i^2 + Y_i^2 + Z_i^2} \quad (3.1)$$

A escolha dos limiares é um fato determinante para o sucesso deste tipo de algoritmo de detecção de quedas. A escolha dos limiares pode ser feita através de experimentos preliminares como em Zhang *et al.* (2013). Em seu trabalho, um grupo de voluntários foi escolhido para realizar diversas ADL, como andar, correr subir e descer escadas e também realizar a simulação de quedas. Através dos dados obtidos foi possível descobrir os limiares de SMV para um evento de queda.

De acordo com Cao *et al.* (2012), a performance dos algoritmos aumenta significativamente quando utilizamos valores de limiar dinâmicos. De acordo com sua pesquisa, o número de eventos de queda que não foram caracterizadas como tal, caíram de 53 para 29 quando o peso, sexo idade foram levados em consideração no momento da definição dos limiares.

Outra questão importante quando utilizado este tipo de algoritmo é o número de limiares utilizados. De acordo com Casilari *et al.* (2015), o uso de um único limiar faz com que o algoritmo emita um número grande de alerta falsos, categorizando ADL como

eventos de queda, fazendo com que o uso de somente um limiar não seja adequado no desenvolvimento de [FDS](#).

3.4 Trabalhos Relacionados

d

Referências Bibliográficas

- Abbate, S., Avvenuti, M., Cola, G., Corsini, P., Light, J., and Vecchio, A. (2011). Recognition of false alarms in fall detection systems. In *2011 IEEE Consumer Communications and Networking Conference (CCNC)*, pages 23–28. IEEE.
- Anzai, Y. (2012). *Pattern Recognition & Machine Learning*. Elsevier.
- Cao, Y., Yang, Y., and Liu, W. (2012). E-falld: A fall detection system using android-based smartphone. In *Fuzzy Systems and Knowledge Discovery (FSKD), 2012 9th International Conference on*, pages 1509–1513. IEEE.
- Casilari, E., Luque, R., and Morón, M.-J. (2015). Analysis of android device-based solutions for fall detection. *Sensors*, **15**(8), 17827–17894.
- Cucchiara, R., Grana, C., Prati, A., and Vezzani, R. (2005). Probabilistic posture classification for human-behavior analysis. *IEEE Transactions on systems, man, and cybernetics-Part A: Systems and Humans*, **35**(1), 42–54.
- Foroughi, H., Naseri, A., Saberi, A., and Yazdi, H. S. (2008). An eigenspace-based approach for human fall detection using integrated time motion image and neural network. In *2008 9th International Conference on Signal Processing*, pages 1499–1503. IEEE.
- Gartner (2015). Gartner says smartphone sales surpassed one billion units in 2014. <http://www.gartner.com/newsroom/id/2996817/>. Acessado em 22 de Abril de 2016.
- Gjoreski, H., Lustrek, M., and Gams, M. (2011). Accelerometer placement for posture recognition and fall detection. In *Intelligent environments (IE), 2011 7th international conference on*, pages 47–54. IEEE.
- Google (2016a). Sensor coordinate system. https://developer.android.com/guide/topics/sensors/sensors_overview.html#sensors-intro. Acessado em 10 de Setembro de 2016.
- Google (2016b). Using the gyroscope. http://developer.android.com/guide/topics/sensors/sensors_motion.html#sensors-motion-gyro. Acessado em 08 de Maio de 2016.

REFERÊNCIAS BIBLIOGRÁFICAS

- Habib, M. A., Mohktar, M. S., Kamaruzzaman, S. B., Lim, K. S., Pin, T. M., and Ibrahim, F. (2014). Smartphone-based solutions for fall detection and prevention: challenges and open issues. *Sensors*, **14**(4), 7181–7208.
- He, Y., Li, Y., and Bao, S.-D. (2012). Fall detection by built-in tri-accelerometer of smartphone. *Proceedings of 2012 IEEE-EMBS International Conference on Biomedical and Health Informatics*, **25**, 184–187.
- Hsieh, S.-L., Chen, C.-C., Wu, S.-H., and Yue, T.-W. (2014). A wrist-worn fall detection system using accelerometers and gyroscopes. In *Networking, Sensing and Control (ICNSC), 2014 IEEE 11th International Conference on*, pages 518–523. IEEE.
- IBGE (2012). Número de idosos que moram sozinhos triplica em 20 anos. http://www.ibge.gov.br/home/estatistica/populacao/trabalhoerendimento/pnad2012/default_sintese.shtm. Acessado em 21 de Abril de 2016.
- IBGE (2016). Projeção da população do brasil e das unidades da federação. <http://www.ibge.gov.br/apps/populacao/projecao/>. Acessado em 21 de Abril de 2016.
- Igual, R., Medrano, C., and Plaza, I. (2013). Challenges, issues and trends in fall detection systems. *Biomedical engineering online*, **12**(1), 1.
- Kangas, M., Konttila, A., Winblad, I., and Jamsa, T. (2007). Determination of simple thresholds for accelerometry-based parameters for fall detection. In *2007 29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 1367–1370. IEEE.
- Legters, K. (2002). Fear of falling. *Physical therapy*, **82**(3), 264–272.
- Lukowicz, P., Kirstein, T., and Troster, G. (2004). Wearable systems for health care applications. *Methods of Information in Medicine-Methodik der Information in der Medizin*, **43**(3), 232–238.
- Mehner, S., Klauck, R., and Koenig, H. (2013). Location-independent fall detection with smartphone. In *Proceedings of the 6th International Conference on Pervasive Technologies Related to Assistive Environments*, page 11. ACM.
- Milette, G. and Stroud, A. (2012). *Professional Android sensor programming*. John Wiley & Sons.

- Mubashir, M., Shao, L., and Seed, L. (2013). A survey on fall detection: Principles and approaches. *Neurocomputing*, **100**, 144–152.
- Pivato, P., Dalpez, S., Macii, D., and Petri, D. (2011). A wearable wireless sensor node for body fall detection. In *Measurements and Networking Proceedings (M&N), 2011 IEEE International Workshop on*, pages 116–121. IEEE.
- Portal Brasil (2012). Quedas. <http://www.brasil.gov.br/saude/2012/04/quedas/>. Acessado em 21 de Abril de 2016.
- Rougier, C. and Meunier, J. (2005). Demo: Fall detection using 3d head trajectory extracted from a single camera video sequence. *Journal of Telemedicine and Telecare*, **11**(4), 37–42.
- Rougier, C., Meunier, J., St-Arnaud, A., and Rousseau, J. (2011). Robust video surveillance for fall detection based on human shape deformation. *IEEE Transactions on Circuits and Systems for Video Technology*, **21**(5), 611–622.
- Samsung (2016). Gear s2. <http://www.samsung.com/global/galaxy/gear-s2/#!/spec/>. Acessado em 22 de Abril de 2016.
- Sposaro, F. and Tyson, G. (2009). ifall: an android application for fall monitoring and response. In *2009 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 6119–6122. IEEE.
- United Nations (2013). World population ageing 2013. Report, The Department of Economic and Social Affairs of the United Nations.
- Zhang, Q., Ren, L., and Shi, W. (2013). Honey: A multimodality fall detection and telecare system. *Telemedicine and e-Health*, **19**(5), 415–429.
- Zhao, Z., Chen, Y., Wang, S., and Chen, Z. (2012). Fallalarm: Smart phone based fall detecting and positioning system. *Procedia Computer Science*, **10**, 617–624.
- Zhuang, X., Huang, J., Potamianos, G., and Hasegawa-Johnson, M. (2009). Acoustic fall detection using gaussian mixture models and gmm supervectors. In *2009 IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 69–72. IEEE.
-